

SLAM 系统可观性和一致性分析

张谦

2020 年 2 月 23 日

1 无偏估计、有效性和一致性

现实中常常有这样的问题，比如，想知道全体女性的身高均值 μ ，但是没有办法把每个女性都进行测量，只有抽样一些女性来估计全体女性的身高：




图 1: 身高高斯分布示意图

那么根据抽样数据怎么进行推断？什么样的推断方法才称为“好”？

1.1 无偏性

比如说我们采样到的女性身高分别为：

$$\{x_1, x_2, \dots, x_n\} \quad (1)$$

那么：

$$\bar{X} = \frac{x_1 + x_2 + \dots + x_n}{n} \quad (2)$$


是对 μ 不错的一个估计，为什么？以为它是无偏估计。

首先，真正的全体女性的身高均值 μ ，我们是不知道的，只有上帝才知道，在图中就画为虚线，通过采样计算出 \bar{X} 会发现，不同采样得到的 \bar{X} 是围绕 μ 左右波动的。这有点像打靶，只要命中在靶心周围，还算不错的成绩，这就是无偏的。

如果用一下式子去估计总体方差 σ^2 ：


$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \quad (3)$$

会偏离靶心并产生偏差，这就是有偏的，这个偏差为 $\frac{1}{n}\sigma^2$ ，这种偏差就像瞄准镜歪了，属于系统误差，就此而言，无偏估计要好于有偏估计。



知乎 @马同学

图 2: 采样计算 \bar{X}



知乎 @马同学

图 3: 打靶例子



图 4: 系统偏差




图 5: 有效性示意图

1.2 有效性

打靶的时候，右边的成绩肯定更优秀：进行估计的时候，也是估计量越靠近目标，效果越好，这个靠近可以用方差来衡量。另外，有效估计和偏差性是不想关的。

举个例子，从 $N(\mu, \sigma^2)$ 中抽出 10 个样本：

$$\{x_1, x_2, \dots, x_n\} \quad (4)$$


下面两个都是无偏估计量：

$$T_1 = \frac{x_1 + x_3 + 2x_{10}}{4}, T_2 = \frac{1}{10} \sum_{i=1}^{10} x_i \quad (5)$$

但是后者比前者方差小，后者更有效。并且显示中不一定非要选无偏估计量，比如：如果能接受点误差，选择右边这个估计量更好。

更有效

无偏




有偏




知乎 @马同学

无偏，有效性差



有偏，有效性好



知乎 @马同学

1.3 一致性

之前说了，如果用以下式子去估计方差 σ^2 :

$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \quad (6)$$

会有一个偏差 $\frac{1}{n}\sigma^2$ ，可以看到，随着采样个数 n 的增加，这个偏差会越来越小。那么这个估计量就是“一致的”。如果样本数量够多，其实这种“有偏”但是“一致”的估计量也是可以选的。

1.4 总结

在共视的 Mapping 中，由于 fix 历史帧，优化滑窗内的关键帧，导致的“有偏”估计，但是由于前端 vio 能够提供无偏且一致的初值，会提升后端共视非线性优化的“有效性”，而且最终使得 SLAM 能有一个比较精确的输出。

2 非线性系统可观性分析

2.1 Lie Derivative

在介绍 Lie Derivative 之前，先需要以下一些概念。

(1) 向量函数 $f(\mathbf{x}) : \mathbb{R}^n \rightarrow \mathbb{R}^n$ (从 $\mathbf{x} \in \mathbb{R}^n$ 映射到 $f(\mathbf{x}) \in \mathbb{R}^n$)，叫做 \mathbb{R}^n 里的向量场 (Vector field)。如果进一步，向量函数 f 具有连续偏导，而且是任意阶的偏导，那么我们说 f 是光滑向量场 (Smooth Vector field)。

(2) 光滑标量函数 $h(\mathbf{x}) : \mathbb{R}^n \rightarrow \mathbb{R}$ (从 $\mathbf{x} \in \mathbb{R}^n$ 映射到 $h(\mathbf{x}) \in \mathbb{R}$ 的函数) 的 Gradient 由一个行向量 $\nabla h = \frac{\partial h}{\partial \mathbf{x}}$ 表示，其中 $\mathbf{x} \in \mathbb{R}^n$ 。所以我们要记住，Gradient 是标量对向量的求导，其结果是个行向量。光滑向量场 $f(\mathbf{x})$ 的 Jacobian 由一个 $n \times n$ 的矩阵 $\nabla f = \frac{\partial f}{\partial \mathbf{x}}$ ，其中矩阵的第一行就是 $\nabla f_1 = \frac{\partial f_1}{\partial \mathbf{x}}$ ，就是刚刚定义的光滑标量函数 f_1 (列向量 f 的第一个元素) 的 Gradient，而我们知道 Gradient 是行向量。以此类推 Jacobian 的第 i 行应该为 $\nabla f_i = \frac{\partial f_i}{\partial \mathbf{x}}$ 。那么基于以上几个定义，我们就可以用来定义 Lie Derivative。

(3) Lie Derivative 的定义：光滑标量函数 $h(\mathbf{x}) : \mathbb{R}^n \rightarrow \mathbb{R}$ 相对于光滑向量场 $f(\mathbf{x}) : \mathbb{R}^n \rightarrow \mathbb{R}^n$ 的 Lie Derivative 由一个标量函数 $L_f h = \nabla h \mathbf{f} = \frac{\partial h}{\partial \mathbf{x}} \mathbf{f}$ 表示，其中 $\frac{\partial h}{\partial \mathbf{x}}$ 就是标量函数 $h(\mathbf{x})$ 的 Gradient，是个行向量。行向量 $\frac{\partial h}{\partial \mathbf{x}}$ 乘以向量场 $f(\mathbf{x}) \in \mathbb{R}^n$ ，其结果正好是个标量，所以 $L_f h = \nabla h \mathbf{f} = \frac{\partial h}{\partial \mathbf{x}} \mathbf{f}$ 是个标量。

(4) 如果 $g(\mathbf{x}) : \mathbb{R}^n \rightarrow \mathbb{R}^n$ 是另一个向量场，由于刚刚计算的 Lie Derivative: $L_f h$ 是个标量，它又可以跟 $g(\mathbf{x})$ 算出一个 Lie Derivative，表示为 $L_g L_f h = L_g(L_f h) = \nabla(L_f h)g = \frac{\partial(L_f h)}{\partial \mathbf{x}}g = \frac{\partial(\frac{\partial h}{\partial \mathbf{x}} \mathbf{f})}{\partial \mathbf{x}}g$ ，当然同样地，算出来 $L_g L_f h$ 的结果依然是个标量。以此类推，可以一直搞下去。于是我们有标量函数 $h(\mathbf{x}) : \mathbb{R}^n \rightarrow \mathbb{R}$ 的 0 阶 Lie Derivative，表示为 $L_f^0 h = h$ ，是它本身。标量函数 $h(\mathbf{x}) : \mathbb{R}^n \rightarrow \mathbb{R}$ 的第 i 阶 Lie Derivative 为 $L_f^i h = L_f(L_f^{i-1} h) = \nabla(L_f^{i-1} h)\mathbf{f} = \frac{\partial(L_f^{i-1} h)}{\partial \mathbf{x}}\mathbf{f}$ 。

(5) 总结一下，Lie Derivative 与一般的 Derivate 的区别是，Lie Derivative 是定义在两个函数 h 和 f 之间的，它俩都是向量 \mathbf{x} 的函数，标量函数 h 对 \mathbf{x} 的 Gradient 乘以 $f(\mathbf{x})$ ，它们通过共同的 \mathbf{x} 联系起来的。一般的 Derivative 是某个函数对 \mathbf{x} 定义的。举个例子，对于单输出非线性系统：

$$\begin{aligned} \dot{\mathbf{x}} &= \mathbf{f}(\mathbf{x}) \\ y &= h(\mathbf{x}) \end{aligned} \quad (7)$$

$$\text{我们有 } \dot{y} = \frac{\partial h}{\partial \mathbf{x}} \dot{\mathbf{x}} = \frac{\partial h}{\partial \mathbf{x}} \mathbf{f}(\mathbf{x}) = L_f h, \quad \ddot{y} = \frac{\partial(L_f h)}{\partial \mathbf{x}} \dot{\mathbf{x}} = \frac{\partial(L_f h)}{\partial \mathbf{x}} \mathbf{f}(\mathbf{x}) = L_f^2 h$$

2.2 非线性系统的 Lie Derivative 和可观矩阵

考虑连续非线性系统：

$$\begin{aligned} \dot{\mathbf{x}} &= \mathbf{f}_0(\mathbf{x}) + \sum_{i=1}^l \mathbf{f}_i(\mathbf{x}) \mathbf{u}_i \\ \mathbf{z} &= \mathbf{h}(\mathbf{x}) \end{aligned} \quad (8)$$

其中控制输入 $\mathbf{u} = [u_1, u_2, \dots, u_l]^T$ ，状态量 $\mathbf{x} = [x_1, x_2, \dots, x_m]^T$ ，状态过程模型表示为向量函数 $\mathbf{f}_i, i = 0, 1, \dots, l$ 。

为了分析系统的可观性，以及在现有的测量下状态量各个方向的可观性，我们计算系统的 Lie Derivative。定义测量函数 \mathbf{h} 的零阶 Lie Derivative 为其自身：

$$\mathcal{L}^0 \mathbf{h} = \mathbf{h}(\mathbf{x}) \quad (9)$$

由 Lie Derivative 的定义，测量函数 \mathbf{h} 不同阶的 Lie Derivative 由 $\mathcal{L}^0 \mathbf{h}$ 循环计算得到。其中，由第 i 阶 Lie Derivative, $\mathcal{L}^i \mathbf{h}$ 和状态过程函数 \mathbf{f}_j 可计算得到测量函数的第 $i+1$ 阶 Lie Derivative $\mathcal{L}_{\mathbf{f}_j}^{i+1} \mathbf{h}$ ：

$$\mathcal{L}_{\mathbf{f}_j}^{i+1} \mathbf{h} = \nabla \mathcal{L}^i \mathbf{h} \cdot \mathbf{f}_j \quad (10)$$

其中 $\nabla \mathcal{L}^i \mathbf{h}$ 为第 i 阶 Lie Derivative 的生成空间：

$$\nabla \mathcal{L}^i \mathbf{h} = \left[\frac{\partial \mathcal{L}^i \mathbf{h}}{\partial x_1}, \frac{\partial \mathcal{L}^i \mathbf{h}}{\partial x_2}, \dots, \frac{\partial \mathcal{L}^i \mathbf{h}}{\partial x_m} \right] \quad (11)$$

由给定的观测信息，为了分析在哪些方向上是可观的，我们检查测量函数各阶 Lie Derivative 的生成空间，且定义可观矩阵为

$$\mathcal{O} = \begin{bmatrix} \nabla \mathcal{L}^0 \mathbf{h} \\ \nabla \mathcal{L}_{\mathbf{f}_i}^1 \mathbf{h} \\ \nabla \mathcal{L}_{\mathbf{f}_i \mathbf{f}_j}^2 \mathbf{h} \\ \nabla \mathcal{L}_{\mathbf{f}_i \mathbf{f}_j \mathbf{f}_k}^3 \mathbf{h} \\ \vdots \end{bmatrix} \quad (12)$$

其中 $i, j, k = 1, 2, \dots, l$ 。为了证明系统是可观的，需要证明 \mathcal{O} 的若干行组成的子矩阵是列满秩的（full column rank）。相反的，为了证明系统是非完全可观的，且找出不可观的方向，则需要证明：（a）矩阵 \mathcal{O} 中的无限多行，均可表示为矩阵 \mathcal{O}' 行向量的线性组合，其中 \mathcal{O}' 的行向量来自于 \mathcal{O} ；（b）求解矩阵 \mathcal{O}' 的零空间，即可得到系统不可观的方向。尽管条件（b）可以直接求解得到，但是条件（a）很难找到。

2.3 非线性系统可观性分析

通过上面介绍可知，要分析非线性系统的可观性，是非常有挑战的，因为要计算具有无限行组成的可观矩阵的零空间。但是论文中提出了一种方法，使可观性分析变得容易，将可观矩阵分解为两个矩阵相乘：一个满秩的无限行矩阵和一个非满秩的有限行矩阵。下面将通过计算一系列关于状态变量 \mathbf{x} 的基函数，来达到分解可观矩阵的目的。

首先给出定理，

Theorem1: 假设存在非线性变换 $\beta(\mathbf{x}) = [\beta_1(\mathbf{x})^T, \dots, \beta_t(\mathbf{x})^T]^T$ ，这些基均是关于状态变量 \mathbf{x} 的函数，总共有 t 个，且满足如下条件：

（C1） $\beta_1(\mathbf{x}) = \mathbf{h}(\mathbf{x})$ ；

（C2） $\frac{\partial \beta}{\partial \mathbf{x}} \cdot \mathbf{f}_i(\mathbf{x}), i = 0, 1, \dots, l$ 是关于 β 的函数；

（C3）定义一个可观的非线性系统：

$$\begin{cases} \dot{\beta} = \mathbf{g}_0(\beta) + \sum_{i=1}^l \mathbf{g}_i(\beta) \mathbf{u}_i \\ \mathbf{z} = \mathbf{h} = \beta_1 \end{cases} \quad (13)$$

其中， $\mathbf{g}_i(\beta) = \frac{\partial \beta}{\partial \mathbf{x}} \mathbf{f}_i(\mathbf{x}), i = 0, 1, \dots, l$ 。

根据以上假设条件，则有以下两条结论：

（i）可观矩阵 \mathcal{O} 可被分解为：

$$\mathcal{O} = \Xi \cdot \mathbf{B} \quad (14)$$

其中 Ξ 为系统（13）的可观矩阵，且 $\mathbf{B} \triangleq \frac{\partial \beta}{\partial \mathbf{x}}$ 。

（ii） $\text{null}(\mathcal{O}) = \text{null}(\mathbf{B})$

证明结论（i）：根据链式法则，Lie Derivative $\nabla \mathcal{L}^i \mathbf{h}$ 的生成空间可表示为，

$$\nabla \mathcal{L}^i \mathbf{h} = \frac{\partial \mathcal{L}^i \mathbf{h}}{\partial \mathbf{x}} = \frac{\partial \mathcal{L}^i \mathbf{h}}{\partial \beta} \frac{\partial \beta}{\partial \mathbf{x}} \quad (15)$$

因此，系统（8）的可观矩阵 \mathcal{O} 可被分解为：

$$\mathcal{O} = \begin{bmatrix} \nabla \mathcal{L}^0 \mathbf{h} \\ \nabla \mathcal{L}_{\mathbf{f}_i}^1 \mathbf{h} \\ \nabla \mathcal{L}_{\mathbf{f}_i \mathbf{f}_j}^2 \mathbf{h} \\ \nabla \mathcal{L}_{\mathbf{f}_i \mathbf{f}_j \mathbf{f}_k}^3 \mathbf{h} \\ \vdots \end{bmatrix} = \begin{bmatrix} \frac{\partial \mathcal{L}^0 \mathbf{h}}{\partial \beta} \\ \frac{\partial \mathcal{L}_{\mathbf{f}_i}^1 \mathbf{h}}{\partial \beta} \\ \frac{\partial \mathcal{L}_{\mathbf{f}_i \mathbf{f}_j}^2 \mathbf{h}}{\partial \beta} \\ \frac{\partial \mathcal{L}_{\mathbf{f}_i \mathbf{f}_j \mathbf{f}_k}^3 \mathbf{h}}{\partial \beta} \\ \vdots \end{bmatrix} \frac{\partial \beta}{\partial \mathbf{x}} = \Xi \cdot \mathbf{B} \quad (16)$$

接下来证明矩阵 Ξ 是系统（13）的可观矩阵。

为区分系统（8）和系统（13）的各阶 Lie Derivative，利用符号 \mathcal{J} 表示系统（13）的 Lie Derivative。系统（13）的零阶 Lie Derivative 的生成空间表示为：

$$\nabla \mathcal{J}^0 \mathbf{h} = \frac{\partial \mathbf{h}}{\partial \beta} = \frac{\partial \mathcal{L}^0 \mathbf{h}}{\partial \beta} \quad (17)$$

该零阶生成空间即为矩阵 Ξ 的第一行块矩阵。

利用 $\nabla \mathcal{J}^i \mathbf{h} = \frac{\partial \mathcal{L}^i \mathbf{h}}{\partial \beta}$ 表示矩阵 Ξ 的 i 行 Lie Derivative 的生成空间，则第 $i+1$ 行的生成空间 $\nabla \mathcal{J}_{\mathbf{g}_j}^{i+1} \mathbf{h}$ （状态过程函数为 \mathbf{g}_j ）可表示为

$$\nabla \mathcal{J}_{\mathbf{g}_j}^{i+1} \mathbf{h} = \frac{\partial \mathcal{J}_{\mathbf{g}_j}^{i+1} \mathbf{h}}{\partial \beta} = \frac{\partial \nabla \mathcal{J}^i \mathbf{h} \cdot \mathbf{g}_j}{\partial \beta} = \frac{\partial (\frac{\partial \mathcal{L}^i \mathbf{h}}{\partial \beta} \cdot \frac{\partial \beta}{\partial \mathbf{x}} \cdot \mathbf{f}_j(\mathbf{x}))}{\partial \beta} = \frac{\partial (\frac{\partial \mathcal{L}^i \mathbf{h}}{\partial \mathbf{x}} \cdot \mathbf{f}_j(\mathbf{x}))}{\partial \beta} = \frac{\partial \mathcal{L}_{\mathbf{f}_j}^{i+1} \mathbf{h}}{\partial \beta} \quad (18)$$

因此，矩阵 Ξ 的每一行矩阵块，为系统（13）的各阶 Lie Derivative 的生成空间，即矩阵 Ξ 是系统（13）的可观矩阵。

证明结论（ii）：由于 $\mathcal{O} = \Xi \mathbf{B}$ ，则有 $\text{null}(\mathcal{O}) = \text{null}(\mathbf{B}) + \text{null}(\Xi) \cap \text{range}(\mathbf{B})$ [Meyer2000]，另外，由于假设条件（C3）系统（13）是可观的，即可观矩阵 Ξ 为列满秩（full column rank），则有 $\text{null}(\mathcal{O}) = \text{null}(\mathbf{B})$ 。至此，由假设条件（C1）、（C2）和（C3）得到的结论（i）和（ii）证毕。

由 **Theorem1** 可知，为了分析一个系统的不可观方向，首先需要找到一些基函数（basis functions）满足条件（C1）和（C2），并且需要证明矩阵 Ξ 是列满秩（full column rank），即满足条件（C3）。当着三个条件满足后，则系统（8）的不可观方向分析转换成求解矩阵 \mathbf{B} 的零空间。由于矩阵 \mathbf{B}_I 是有限维的，因此求解零空间很容易。

3 VI-SLAM 系统可观性分析

3.1 系统概述

在该系统中，四元数表示旋转采用 JPL 形式。坐标系约定：全局坐标系用 G 表示，Camera 坐标系用 C 表示，IMU 坐标系用 I 表示，地图点用 f 表示；相机、IMU 和地图点表示在某个坐标系下，则该坐标系符号写在对应变量的左上角，变量标识写在变量符号的右下角，例如 ${}^G \mathbf{p}_I$ 表示 IMU 系（body 系）原点在全局坐标系中的位置（平移）， ${}^G \mathbf{v}_I$ 表示 IMU 系在全局坐标系下的速度， ${}^I \mathbf{q}_G$ 表示从全局坐标系旋转到 IMU 系的单位四元数，由于采用 JPL 形式，旋转均是由 G 系到 I 系旋转，与 Hamilton 表示方式相反； ${}^G \mathbf{p}_{f_i}$ 表示第 i 个地图点在 G 系下的坐标。

状态变量包含位姿、速度、Bias 和地图点：

$$\mathbf{x} = \left[{}^I \mathbf{q}_G^T, \mathbf{b}_g^T, {}^G \mathbf{v}_I^T, \mathbf{b}_a^T, {}^G \mathbf{p}_I^T \mid {}^G \mathbf{p}_{f_1}^T, \dots, {}^G \mathbf{p}_{f_N}^T \right]^T = [\mathbf{x}_s^T \mid \mathbf{x}_m^T]^T \quad (19)$$

其中 \mathbf{x}_s^T 和 \mathbf{x}_m^T 分别表示 16×1 维传感器状态和 $3N \times 1$ 维地图点状态。

连续系统状态模型：

$${}^I \dot{\mathbf{q}}_G(t) = \frac{1}{2} ({}^I \omega(t)) {}^I \mathbf{q}_G(t) \quad (20)$$

$${}^G \dot{\mathbf{p}}_I(t) = {}^G \mathbf{v}_I(t) \quad (21)$$

$${}^G \dot{\mathbf{v}}_I(t) = {}^G \mathbf{a}_I(t) \quad (22)$$

$$\dot{\mathbf{b}}_g(t) = \mathbf{n}_{wg}(t) \quad (23)$$

$$\dot{\mathbf{b}}_a(t) = \mathbf{n}_{wa}(t) \quad (24)$$

$${}^G \dot{\mathbf{p}}_{f_i}(t) = \mathbf{0}_{3 \times 1}, i = 1, \dots, N \quad (25)$$

其中,

$$\Omega(\omega) = \begin{bmatrix} -[\omega]_{\times} & \omega \\ -\omega^T & \mathbf{0} \end{bmatrix} \quad (26)$$

$$[\omega]_{\times} \triangleq \begin{bmatrix} 0 & -\omega_3 & \omega_2 \\ \omega_3 & 0 & -\omega_1 \\ -\omega_2 & \omega_1 & 0 \end{bmatrix} \quad (27)$$

陀螺仪测量 ${}^I\omega_m$ 和加速度计测量 ${}^I\mathbf{a}_m$ 模型为:

$${}^I\omega_m(t) = {}^I\omega(t) + \mathbf{b}_g(t) + \mathbf{n}_g(t) \quad (28)$$

$${}^I\mathbf{a}_m(t) = \mathbf{C}({}^I\mathbf{q}_G(t))({}^G\mathbf{a}_I(t) - {}^G\mathbf{g}) + \mathbf{b}_a(t) + \mathbf{n}_a(t) \quad (29)$$

其中 $\mathbf{C}(\mathbf{q})$ 表示四元数对应的选择矩阵。

对于上述连续状态模型, 在当前时刻的估计量处线性展开, 并求期望, 得到状态估计的传递模型:

$${}^I\dot{\hat{\mathbf{q}}}_G(t) = \frac{1}{2} ({}^I\hat{\omega}(t)) {}^I\hat{\mathbf{q}}_G(t) \quad (30)$$

$${}^G\dot{\hat{\mathbf{p}}}_I(t) = {}^G\hat{\mathbf{v}}_I(t) \quad (31)$$

$${}^G\dot{\hat{\mathbf{v}}}_I(t) = \mathbf{C}^T({}^I\hat{\mathbf{q}}_G(t)) {}^I\hat{\mathbf{a}}(t) + {}^G\mathbf{g} \quad (32)$$

$$\dot{\hat{\mathbf{b}}}_g(t) = \mathbf{0}_{3 \times 1} \quad (33)$$

$$\dot{\hat{\mathbf{b}}}_a(t) = \mathbf{0}_{3 \times 1} \quad (34)$$

$${}^G\dot{\hat{\mathbf{p}}}_{f_i}(t) = \mathbf{0}_{3 \times 1}, i = 1, \dots, N \quad (35)$$

其中 ${}^I\hat{\mathbf{a}}(t) = {}^I\mathbf{a}_m(t) - \hat{\mathbf{b}}_a(t)$, ${}^I\hat{\omega}(t) = {}^I\omega_m(t) - \hat{\mathbf{b}}_g(t)$

根据误差状态 (error state) 的定义 $\tilde{\mathbf{x}} = \mathbf{x} - \hat{\mathbf{x}}$ 有:

$$\tilde{\mathbf{x}} = \left[{}^I\delta\theta_G^T, \tilde{\mathbf{b}}_g^T, {}^G\tilde{\mathbf{v}}_I^T, \tilde{\mathbf{b}}_a^T, {}^G\tilde{\mathbf{p}}_I^T | {}^G\tilde{\mathbf{p}}_{f_1}^T, \dots, {}^G\tilde{\mathbf{p}}_{f_N}^T \right]^T = [\tilde{\mathbf{x}}_s^T | \tilde{\mathbf{x}}_m^T]^T \quad (36)$$

则有线性连续误差状态方程,

$$\dot{\tilde{\mathbf{x}}} = \begin{bmatrix} \mathbf{F}_s & \mathbf{0}_{15 \times 3N} \\ \mathbf{0}_{3N \times 15} & \mathbf{0}_{3N} \end{bmatrix} \tilde{\mathbf{x}} + \begin{bmatrix} \mathbf{G}_s \\ \mathbf{0}_{3N \times 12} \end{bmatrix} \mathbf{n} = \mathbf{F}_c \tilde{\mathbf{x}} + \mathbf{G}_c \mathbf{n} \quad (37)$$

其中,

$$\mathbf{n} = [\mathbf{n}_g^T, \mathbf{n}_{wg}^T, \mathbf{n}_a^T, \mathbf{n}_{wa}^T]^T \quad (38)$$

$$\mathbf{F}_s = \begin{bmatrix} -[\hat{\omega}]_{\times} & -\mathbf{I}_3 & \mathbf{0}_3 & \mathbf{0}_3 & \mathbf{0}_3 \\ \mathbf{0}_3 & \mathbf{0}_3 & \mathbf{0}_3 & \mathbf{0}_3 & \mathbf{0}_3 \\ -\mathbf{C}^T({}^I\hat{\mathbf{q}}_G)[{}^I\hat{\mathbf{a}}]_{\times} & \mathbf{0}_3 & \mathbf{0}_3 & -\mathbf{C}^T({}^I\hat{\mathbf{q}}_G) & \mathbf{0}_3 \\ \mathbf{0}_3 & \mathbf{0}_3 & \mathbf{0}_3 & \mathbf{0}_3 & \mathbf{0}_3 \\ \mathbf{0}_3 & \mathbf{0}_3 & \mathbf{I}_3 & \mathbf{0}_3 & \mathbf{0}_3 \end{bmatrix} \quad (39)$$

$$\mathbf{G}_s = \begin{bmatrix} -\mathbf{I}_3 & \mathbf{0}_3 & \mathbf{0}_3 & \mathbf{0}_3 \\ \mathbf{0}_3 & \mathbf{I}_3 & \mathbf{0}_3 & \mathbf{0}_3 \\ \mathbf{0}_3 & \mathbf{0}_3 & -\mathbf{C}^T({}^I\hat{\mathbf{q}}_G) & \mathbf{0}_3 \\ \mathbf{0}_3 & \mathbf{0}_3 & \mathbf{0}_3 & \mathbf{I}_3 \\ \mathbf{0}_3 & \mathbf{0}_3 & \mathbf{0}_3 & \mathbf{0}_3 \end{bmatrix} \quad (40)$$

$$\mathbb{E}[\mathbf{n}(t)\mathbf{n}^T(\tau)] = \mathbf{Q}_c\delta(t - \tau) \quad (41)$$

接下来讨论离散形式的系统模型：假设陀螺仪信号 ${}^I\omega_m(t)$ 和加速度计信号 ${}^I\mathbf{a}_m(t)$ 采样间隔为 $\delta t \triangleq t_{k+1} - t_k$ ，每次采样后，系统估计状态的传递，利用公式（30）-（35）积分得到。估计状态的协方差通过如下公式得到：

$$\begin{aligned}\dot{\Phi}_{k+1,k} &= \mathbf{F}_c \Phi_{k+1,k} \\ \text{initial condition : } \Phi_{k,k} &= \mathbf{I}_{15+3N}\end{aligned}\quad (42)$$

$$\mathbf{P}_{k+1|k} = \Phi_{k+1,k} \mathbf{P}_{k|k} \Phi_{k+1,k}^T + \mathbf{Q}_{d,k} \quad (43)$$

其中离散的系统噪声协方差矩阵 $\mathbf{Q}_{d,k}$ 通过如下积分计算，

$$\mathbf{Q}_{d,k} = \int_{t_k}^{t_{k+1}} \Phi(t_{k+1}, \tau) \mathbf{G}_c \mathbf{Q}_c \mathbf{G}_c^T \Phi^T(t_{k+1}, \tau) d\tau \quad (44)$$

下面讨论视觉观测模型：为简化问题分析，假设只有一个地图点 \mathbf{p}_{f_i} ，其对应相机测量 \mathbf{z}_i 为地图点 ${}^I\mathbf{p}_{f_i}$ 在图像平面上的投影，即有

$$\mathbf{z}_i = \frac{1}{p_z} \begin{bmatrix} p_x \\ p_y \end{bmatrix} + \eta_i \quad (45)$$

其中

$$\begin{bmatrix} p_x \\ p_y \\ p_z \end{bmatrix} = {}^I\mathbf{p}_{f_i} = \mathbf{C}({}^I\mathbf{q}_G)({}^G\mathbf{p}_{f_i} - {}^G\mathbf{p}_I) \quad (46)$$

且 η_i 为协方差为 \mathbf{R}_i 的高斯白噪声。注意：该视觉观察模型假设图像测量为归一化平面，且相机坐标系和 IMU 坐标系重合，在实际中，相机和 IMU 之间存在内外参。

视觉观测的误差模型表示为

$$\tilde{\mathbf{z}}_i = \mathbf{z}_i - \hat{\mathbf{z}}_i \simeq \mathbf{H}_i \tilde{\mathbf{x}} + \eta_i \quad (47)$$

其中 $\hat{\mathbf{z}} = \mathbf{h}(\hat{\mathbf{x}})$ 是利用当前时刻估计状态 $\hat{\mathbf{x}}$ 通过模型（45）-（46）计算得到，且视觉测量雅可比矩阵 \mathbf{H}_i 为

$$\mathbf{H}_i = \mathbf{H}_c [\mathbf{H}_\theta \quad \mathbf{0}_{3 \times 9} \quad \mathbf{H}_p \quad | \quad \mathbf{0}_3 \dots \mathbf{H}_{f_i} \dots \mathbf{0}_3] \quad (48)$$

其中

$$\mathbf{H}_c = \frac{\partial \mathbf{h}}{\partial {}^I\mathbf{p}_{f_i}} = \frac{1}{p_z^2} \begin{bmatrix} p_z & 0 & -p_x \\ 0 & p_z & -p_y \end{bmatrix} \quad (49)$$

$$\mathbf{H}_\theta = \frac{\partial {}^I\mathbf{p}_{f_i}}{\partial \theta} = [\mathbf{C}({}^I\mathbf{q}_G)({}^G\mathbf{p}_{f_i} - {}^G\mathbf{p}_I)]_\times \quad (50)$$

$$\mathbf{H}_p = \frac{\partial {}^I\mathbf{p}_{f_i}}{\partial {}^G\mathbf{p}_I} = -\mathbf{C}({}^I\mathbf{q}_G) \quad (51)$$

$$\mathbf{H}_{f_i} = \frac{\partial {}^I\mathbf{p}_{f_i}}{\partial {}^G\mathbf{p}_{f_i}} = \mathbf{C}({}^I\mathbf{q}_G) \quad (52)$$

References

- [1] Meyer CD (2000) Matrix Analysis and Applied Linear Algebra. Philadelphia, PA: SIAM.